

Tarea de Laboratorio 2: MongoDB INF-325 Bases de Datos Avanzadas

Profesor: Mauricio Figueroa Colarte

08 de mayo de 2026

1 CONTEXTO

En el marco del avance de los sistemas inteligentes, las búsquedas tradicionales han dado paso a arquitecturas más sofisticadas como los sistemas **RAG (Retrieval-Augmented Generation)**, que integran modelos de lenguaje con bases de datos vectoriales para realizar búsquedas semánticas (Lewis et al., 2020).

Este laboratorio tiene como objetivo simular una base de datos vectorial sobre una infraestructura local de **MongoDB** configurada como Replica Set en Docker. Se trabajará con un corpus de discursos históricos que será procesado mediante herramientas de NLP para su vectorización (*embeddings*) (Mikolov et al., 2013). A través de esta experiencia, los estudiantes conocerán, en lo esencial, los principios de bases de datos documentales, indexación semántica, recuperación de información por similitud y alta disponibilidad.

2 REQUISITOS

1. Implementar la arquitectura de *Cluster* con un set de 3 réplicas. Una de las máquinas será el primario y las otras dos serán los secundarios. Esta configuración deberá estar operativa en su máquina local, donde se levantarán las 3 instancias de **Docker** con cada uno de los servicios de **MongoDB** con la redundancia de la Base de Datos llamada “**Política**” que contendrá la colección de documentos llamada “**Discursos**”. En la siguiente imagen se muestra la arquitectura requerida.




Figura 1: Arquitectura General



2. Realice el preprocesamiento del corpus textual considerando lo siguiente:

- Utilizar un corpus¹ de discursos históricos en formato .txt entregado por el docente (**DiscursosOriginales.rar**).
- Para cada documento:
 - Calcular su hash SHA-256 (Python SHA256, 2023) y usarlo como “_id”.
 - Generar su embedding (vector) utilizando librerías como sentence-transformers (sentence transformer documentation, nd) o spaCy (Spacy, nd).
- Insertar el documento en MongoDB con la siguiente estructura:

```
{
  "_id": "<hash SHA-256>",
  "texto": "<contenido completo>",
  "embedding": [ ... ],
}
```

3. Desarrollar un script en Python que:

- Reciba una consulta textual.
- Genere su embedding.
- Calcule la similitud coseno (Cosine_similarity, n.d.) entre el embedding de consulta y los embeddings almacenados.
- Devuelva los top 5 documentos más similares, ordenados por mayor similitud, mostrando metadatos y puntaje.
- Mostrar resultados por consola o Jupyter Notebook.

4. Una vez realizados los puntos anteriores, se pide mostrar evidencia objetiva que permita demostrar la alta **disponibilidad** del Replica Set, tanto para lectura como escritura de nuevos discursos. Por ejemplo, bajando el servidor primario para que responda alguno de los secundarios **sin que el usuario se percate del problema**.

¹ Según la RAE, **Corpus**: Conjunto lo más extenso y ordenado posible de datos o textos científicos, literarios, etc., que pueden servir de base a una investigación.



3 REFERENCIAS BIBLIOGRÁFICAS

1. Cosine_similarity. (n.d.). Scikit-Learn. Retrieved May 16, 2025, from https://scikit-learn.org/stable/modules/generated/sklearn.metrics.pairwise.cosine_similarity.html.
2. Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Riedel, S. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. Advances in Neural Information Processing Systems, 33, 9459–9474. https://papers.nips.cc/paper_files/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf
3. Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient Estimation of Word Representations in Vector Space. arXiv preprint arXiv:1301.3781. <https://arxiv.org/abs/1301.3781>
4. Python SHA256: Secure hashing implementation. (2023, December 4). Medium. <https://medium.com/@wepypixel/python-sha256-secure-hashing-implementation-pypixel-7b8434a9b244>
5. SentenceTransformers Documentation — Sentence Transformers documentation. (n.d.). Sbert.net. Retrieved May 16, 2025, from <https://sbert.net/>
6. SpaCy · industrial-strength Natural Language Processing in Python. (n.d.). Spacy.io. Retrieved May 16, 2025, from <https://spacy.io/>